

TBankMultimodalLLMs

Тестовое задание для совместной магистратуры МФТИ и ТБАНКА по направлению AI

Цель:

- Обучить компактную модель мира на основе RSSM в стиле PlaNet с MPC планировщиком для игры в простой среде Minigrid

Задачи

- Написать архитектуру модели мира на основе RSSM
- Обучить её и оценить способность к предсказанию состояния мира после совершенных действий.
- Найти подходящую VLM модель чтобы на основе заданной текстовой цели превращать воображаемые будущие кадры в число – оценку достижения заданной цели.
- Написать MPC планировщик и выполнить сравнение планировщика с VLM с random и World model без VLM (используется своя reward model)

Структура репозитория

- Env_tasks – генератор среды Minigrid
- NN – структуры основных нейронных сетей, которые используются в RSSM
- RSSM – мировая модель, оркестратор на NN
- Data – генерация эпизодов для обучения мировой модели
- Qwen_tests – ноутбук для теста модели Qwen
- Train_world_model – ноутбук для обучения мировой модели с тестом на прогнозирование действий
- Test_world_model – ноутбук для запуска и проведения тестов с моделью.

1 MINIGRID

Обучение и тестирование модели мира происходили в фиксированной дискретной среде, сгенерированной с помощью Minigrid. Вид среды представлен на рисунке 1. Границы и геометрия лабиринта остаются неизменными во всех экспериментах, однако начальное положение агента и направление его взгляда инициализируются случайным образом в свободных ячейках (доступно 52 уникальные позиции, 4 направления взгляда, что даёт 208 уникальных состояний агента).

Дизайн среды спроектирован для проверки способности агента выполнять три цели:

- **Key:** «the red agent is right next to the yellow key, pointing at it»
- **Door:** «the red agent is right next to the blue door, pointing at it»
- **Goal:** «the red agent is standing on the green goal square»




Рисунок 1. Результат генерации среды

2 Оценка эффективности VLM в качестве функции награды

Уже на этапе выбора подходящей VLM для задачи были выявлены две серьёзные проблемы

- **Высокая вычислительная сложность.** Планировщику требуется оценить большое количество кадров, а оценка одного кадра занимает примерно секунду, что делает общее время выполнения программы заведомо высоким даже на GPU T4.
- **Слепота моделей.** VLM демонстрируют слабую чувствительность к объектам среды Minigrid и плохо интерпретируют пространственные отношения. Таким образом требуется оценить применимость VLM моделей

Поскольку пространство состояний фиксировано и ограничено (212 уникальных комбинаций позиций и направлений), вычислительный тупик был решен следующим методом: все возможные состояния были заранее оценены с помощью VLM. При оценке сгенерированных воображаемых кадров в процессе планирования используется метод поиска ближайшего соседа (Nearest Neighbor) для сопоставления сгенерированного воображаемого кадра с истинным кадром из кэш-таблицы.

2.1 Тестирование способности VLM моделей различать поставленные цели.

Для выбора оптимального скорера было проведено сравнительное исследование двух моделей семейства Qwen: Qwen2-VL-2B-Instruct и Qwen2.5-VL-3B-Instruct. Модели оценивали вероятность выполнения инструкции $P(\text{"Yes"} \mid \text{текстовая цель})$ для кадров, где агент уже выполнил поставленные цели. Данные кадры представлены на рисунке 2. Отметим, что для каждого кадра проверяется три цели, чтобы оценить возможность модели различать поставленные цели.




Рисунок 2. Кадры с выполненными целями для задач типа key, door, goal

Результаты исследования представлены в таблице1. Модель Qwen2-VL-2B-Instruct не способна дифференцировать задачи в данной среде и, поэтому, не пригодна к использованию. Версия Qwen2.5-VL-3B-Instruct успешно разделяет целевые состояния, однако сохраняет чувствительность к цветам объектов (например, при замене цвета ключа на синий модель начинает путать его с дверью).

Таблица 1. Результаты кросс-валидации целей

Test	Qwen2-VL-2B-Instruct			Result	Qwen2.5-VL-3B-Instruct			Result
	key	door	goal		key	door	goal	
key	0.562	0.469	0.531	key	0.777	0.593	0.679	key
door	0.593	0.531	0.562	key	0.500	0.755	0.562	door
goal	0.562	0.500	0.562	goal	0.378	0.469	0.777	goal

2.2 Анализ ландшафта наград

Визуализация ландшафта наград представлена на рисунке 3. Выявлена проблема несоответствия аттракторов. Истинные целевые состояния не всегда являются глобальными максимумами на карте оценок VLM.

- **Проблема с целью «Goal»:** при использовании исходного промта ячейка с максимальной оценкой находилась за пределами зеленого квадрата. В процессе MPC-планирования это будет приводить (и приводило) к застреванию агента на границе целевой зоны без фактического захода на неё.
- **Проблема с целью «Door»:** ячейка с максимумом также не совпадает с целью, но в отличие от Goal значения близки, что приводит к меньшему числу застреваний




Рисунок 3. Сравнение ландшафта наград для различных текстовых целей

2.3 Коррекция ландшафта наград.

Красный агент перекрывает зеленый квадрат, в результате чего модель скорее всего его просто не видит и выдаёт No. Попробуем сделать промт негативным: **“The green square is no longer visible”**.

Результаты представлены на рисунке 4, визуализации улучшились для целей Key, Door но целевая точка goal по-прежнему не является аттрактором.





Рисунок 4. Сравнение Ландшафта наград для обновлённой текстовой цели Goal

Попробуем произвести масштабирование модели. Возьмем для тестов. Qwen2-VL-7B-Instruct. Результаты представлены на рисунке. Вновь улучшение по всем текстовым целям, но цель goal стала плохой. Видимо модель плохо воспринимает отрицания.



occlusion-проверка — агент СТОИТ НА goal, 4 направления:

`[((8, 8, 0), 0.0959), ((8, 8, 1), 0.051), ((8, 8, 2), 0.0557), ((8, 8, 3), 0.0607)]`

Окончательное предпочтение отдано модели Qwen2-VL-7B-Instruct с целью **Goal the red agent completely overlaps the green square**. Результаты показаны на рисунке ниже. Ландшафт для key, door удалось значительно улучшить, но проблема с Goal осталась, но немного улучшилась.





Рисунок 5. Сравнение ландшафтов оценок до и после выбора оптимальной модели и промта целей

3 Прогнозирование последствий действий с помощью модели мира

Протестируем обученную мировую модель на способность к предсказанию будущего на 10 шагах



Видим, что в целом будущее предсказывается, однако есть проблем

1. Нечёткий сигнал от агента. В некоторых кадрах он прорисован не полностью
2. Раздвоение агента. В некоторых кадрах агент раздваивается, что может приводить к неправильному срабатыванию Reward моделей.

4 Результаты

Результаты по success rate и представлены в таблице и на рисунке ниже.

Method	Success Rate		
	key	door	Goal
Random	0.17	0.23	0.03
WM + Reward	0.17	0.07	0.53
WM + VLM	0.87	0.73	0.52

Как и ожидалось, использование VLM позволяет расширить класс решаемых задач, однако ввиду проблем оценка эффективности reward модели и VLM модели оказываются соизмеримыми.

GIF файлы с успешными и не успешными движениями агента вы можете посмотреть в репозитории. На них как раз таки и видно что

- Агент застревает на краю гоал
- Иногда агент начинает вращаться на месте и никуда не идёт, что приводит к провалу.

5 Заключение

Удалось успешно реализовать мировую модель на основе RSSM в стиле PlaNet. Предсказание на 10 шагах удовлетворительное, но на некоторых кадрах агент либо плохо отрисован или раздваивается. MPC планировщик позволяет успешно.

Сравнение различных методов оценки показало, что VLM планировщик позволяет значительно расширить класс решаемых задач, так как позволяет наделять абстрактные текстовые цели оценкой по воображаемым кадрам.

Основные Failure Models которые были выявлены

- Крайне высокие вычислительные затраты на использование VLM. В Minigrid мы смогли заранее оценить все возможные исходы, так как их мало, но в более сложных средах (например Miniworld) это сделать невозможно.
- Ландшафт оценки оказывается неудовлетворительным для цели Goal. VLM плохо воспринимают отношения перекрытия объектов.
- Вертящейся на пустом месте агент – провал задачи.

Чтобы я попробовал сделать дальше

- Можно попробовать увеличить разрешение анализируемых кадров планировщиком. Протестировать модель другого семейства.
- Сейчас модель мира работает стандартно. Планируем, делаем один шаг, репланируем. Можно попробовать делать несколько шагов, если первый шаг – вращение, пока агент не сдвинется с клетки.
- Если эти проблемы удастся решить, то хотел бы попробовать обучить модель мира для сред Minigrid с разным окружением, с возможностью последовательного выполнения заданных целей